

Projeto Aurora - Documentação técnica

Link Github: <https://github.com/dudatcl/BIA-projeto>

Como vamos usar Magalu Cloud?

1. Máquina Virtual (VM) (onde vive o Ollama Phi-3)

O que é: uma VM é basicamente um "computador dentro de outro computador". A Magalu Cloud tem servidores físicos gigantes, e eles dividem esses servidores em pedaços que pode alugar como se fossem PCs isolados com seu próprio sistema operacional, CPU, memória e disco reservados.

Por que a Aurora usa: o modelo de linguagem (Ollama rodando a aurora, baseado no Phi-3) precisa de um lugar pra rodar 24/7, com recursos garantidos (CPU/RAM). Você não instala um LLM num "servidor compartilhado qualquer" porque ele consome muito processamento, precisa de uma máquina dedicada só pra isso.

2. MKS (Magalu Kubernetes Service) — o "orquestrador"

O que é Kubernetes: a aplicação Aurora não é um programa só, são vários pedacinhos independentes (Worker Aurora, a fila...), cada pedacinho roda dentro de um **container** (uma caixinha isolada com tudo que aquele pedaço precisa pra funcionar). O Kubernetes é o sistema que **gerencia essas caixas**: liga, desliga, reinicia se cair, distribui carga entre elas, escala se precisar de mais cópias.

O que é o MKS especificamente: é a versão do Kubernetes que a Magalu Cloud já entrega pronta e gerenciada, não precisa instalar nem manter o "cérebro" do Kubernetes (chamado control plane), só manda seus containers pra rodar lá.

Por que a Aurora usa: o Worker Aurora (que consome tarefas da fila e chama o RAG/LLM) roda como um container dentro do MKS. Se a demanda aumentar (mais alertas chegando), o Kubernetes consegue subir mais cópias do Worker automaticamente.

3. Kafka self-hosted (rodando dentro do MKS) a "fila"

O que é uma fila de mensagens: em vez de um sistema chamar o outro diretamente e esperar resposta na hora, ele **publica uma mensagem numa fila**, e outro sistema **consome** essa mensagem quando estiver pronto. Isso desacopla os dois lados, um pode estar ocupado ou fora do ar que a mensagem fica esperando.

Por que a Aurora precisa disso: quando o evento anonimizado chega do banco, ele não vai direto pro Worker Aurora processar na hora. Ele entra numa fila (Kafka).

Projeto Aurora - Documentação técnica

Isso evita que picos de eventos derrubem o sistema, o Worker processa no ritmo que consegue, sem perder nenhuma mensagem.

Por que "self-hosted": a Magalu Cloud não vende Kafka como um produto pronto tipo "clique aqui e tem uma fila gerenciada". Então, a gente mesma instala o Kafka como um container rodando dentro do MKS .

4. Object Storage, onde ficam as cartilhas e legislação (RAG)

O que é: um espaço pra guardar arquivos (documentos, PDFs, textos) na nuvem, parecido com um Google Drive só que acessado por código/API em vez de interface visual.

Por que a Aurora usa: as cartilhas de orientação e a legislação (que o RAG consulta pra gerar respostas fundamentadas) precisam estar guardadas em algum lugar. Esse Object Storage é a "biblioteca" de onde esses documentos são lidos e transformados em vetores pra busca.

5. VPC

O que é: uma VPC (Virtual Private Cloud) é uma rede privada isolada dentro da nuvem. Por padrão, tudo que você cria na Magalu Cloud pode conversar livremente, a VPC permite você desenhar fronteiras: o que pode falar com o quê, o que é público (acessível pela internet) e o que é privado (só acessível de dentro).

Por que a Aurora usa: pra isolar os componentes internos (fila, Worker, banco vetorial) de acesso externo direto. Só o que precisa ser exposto fica numa parte "pública" da rede; o resto fica trancado.

6. Turia IAM

O que é: IAM significa "Identity and Access Management", é o sistema que controla **quem** (pessoa, serviço, container) tem permissão de acessar **o quê** dentro da sua conta na nuvem.

Por que a Aurora usa: pra garantir que, por exemplo, só o Worker Aurora tem permissão de ler da fila anonimizada, e que ninguém de fora (nem outro serviço interno sem necessidade) consiga acessar o banco vetorial ou a VM do Ollama diretamente.

Juntando tudo num fluxo

Projeto Aurora - Documentação técnica

1. O evento anonimizado **atravessa a VPC** (a cerca) e cai numa **fila Kafka** (rodando dentro do **MKS**, o orquestrador de containers), tudo numa **VM/cluster alugado** na Magalu Cloud.
2. O **Worker Aurora** (outro container no MKS) pega essa tarefa da fila.
3. Ele consulta o **Object Storage** (a biblioteca de cartilhas/legislação) via RAG pra buscar contexto.
4. Manda esse contexto pra **VM do Ollama Phi-3** gerar a resposta.
5. O **Turia IAM** garante que só as peças certas conseguem falar umas com as outras em cada uma dessas etapas.

Fluxo:

<https://www.figma.com/board/7ivF2B6X4PGg43PZ87z9GZ/Data-Flow-Diagram--Community-?node-id=0-1&p=f&t=kMO70mjQ7rIVVG8N-0>

